

KV cache

FP16

FP8

PolarQuant

HQQ

TurboQuant

